

Resumen Cálculo Numérico

basado en el resumen de Fernando Nellmédin

Cristian Escudero

October 31, 2012

1 Métodos Directos

1.1 Eliminación de Gauss

Los elementos de la matriz $A^{(k+1)}$ se calculan:

$$a_{ij}^{(k+1)} = \begin{cases} a_{ij}^{(k)} & \text{si } i \leq k, \\ a_{ij}^{(k)} - \left(\frac{a_{ik}^{(k)}}{a_{kk}^{(k)}} a_{kj}^{(k)} \right) & \text{si } i \geq k+1, \text{ y } j \geq k+1, \\ 0 & \text{si } i \geq k+1, \text{ y } j \leq k. \end{cases}$$

Si tenemos **pivoteo parcial**, trabajamos con el **vector de permutación**:

```
1 # Se resuelve en n - 1 pasos
2 for i = 1 : n - 1
3     if (parcial)
4         # Ponemos la fila con maximo valor
5         [tr, p] = max(abs(Ab(idx(i:n), i)));
6         p = p + i - 1;
7
8         if (idx(i) != idx(p))
9             temp = idx(p);
10            idx(p) = idx(i);
11            idx(i) = temp;
12        end
13    end
14    # ... sigue el metodo...
15 end
```

Y trabajamos usando el `idx(i)` en vez de `i` para los subíndices.

Nota: Si encontramos una columna de ceros, el método no determina una solución **única**.

1.2 Factorización LU

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & 0 & \cdots & 0 \\ l_{21} & l_{22} & \ddots & \vdots \\ \vdots & \vdots & \ddots & 0 \\ l_{n1} & l_{n2} & \cdots & l_{nn} \end{bmatrix} \cdot \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & u_{nn} \end{bmatrix} = LU$$

Ejemplo 3x3:

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \cdot \begin{bmatrix} u_{11} & u_{12} & u_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{bmatrix} = LU$$
$$= \begin{bmatrix} l_{11} u_{11} & l_{11} u_{12} & l_{11} u_{13} \\ l_{21} u_{11} & l_{21} u_{12} + l_{22} u_{22} & l_{21} u_{13} + l_{22} u_{23} \\ l_{31} u_{11} & l_{31} u_{12} + l_{32} u_{22} & l_{31} u_{13} + l_{32} u_{23} + l_{33} u_{33} \end{bmatrix}$$

1.2.1 Factorización de Cholesky

Nota: En a_{ij}^{upper} : $\min(i, j) - 1 = i - 1$; y en a_{ij}^{lower} : $\min(i, j) - 1 = j - 1$.

$$\begin{aligned} a_{ij} &= \sum_{k=1}^{\min(i,j)} l_{ik} u_{kj}, \\ a_{ij}^{upper} &= \sum_{k=1}^{i-1} l_{ik} u_{kj} + l_{ii} u_{ij} & \Rightarrow u_{ij} = \frac{1}{l_{ii}} \left[a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj} \right] \\ a_{ij}^{lower} &= \sum_{k=1}^{j-1} l_{ik} u_{kj} + u_{jj} l_{ij} & \Rightarrow l_{ij} = \frac{1}{u_{jj}} \left[a_{ij} - \sum_{k=1}^{j-1} l_{ik} u_{kj} \right] \end{aligned}$$

$$\text{Factorización de Doolittle } (l_{ii} = 1) \quad u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj}$$

$$\text{Factorización de Crout } (u_{ii} = 1) \quad l_{ij} = a_{ij} - \sum_{k=1}^{j-1} l_{ik} u_{kj}$$

2 Métodos Iterativos

Quiero llevar el SEAL a una forma iterativa ($\mathbf{x} = T\mathbf{x} + C$) para poder resolverla:

$$\begin{aligned} A\mathbf{x} &= \mathbf{b} \\ A &= D - L - U \\ (D - L - U)\mathbf{x} &= \mathbf{b} \end{aligned}$$

Jacobi:

$$\begin{aligned} D\mathbf{x} - (L + U)\mathbf{x} &= \mathbf{b} \\ D\mathbf{x} &= (L + U)\mathbf{x} + \mathbf{b} \\ \mathbf{x} &= D^{-1}(L + U)\mathbf{x} + D^{-1}\mathbf{b} \\ \mathbf{x} &= T\mathbf{x} + C \end{aligned}$$

Gauss-Seidel:

$$\begin{aligned} (D - L)\mathbf{x} - U\mathbf{x} &= \mathbf{b} \\ (D - L)\mathbf{x} &= U\mathbf{x} + \mathbf{b} \\ \mathbf{x} &= (D - L)^{-1}U\mathbf{x} + (D - L)^{-1}\mathbf{b} \\ \mathbf{x} &= T\mathbf{x} + C \end{aligned}$$

SOR:

$$\begin{aligned} (D - wL)\mathbf{x} &= [(1 - w)D + wU]\mathbf{x} + w\mathbf{b} \\ \mathbf{x} &= (D - wL)^{-1}[(1 - w)D + wU]\mathbf{x} + (D - wL)^{-1}w\mathbf{b} \\ \mathbf{x} &= T\mathbf{x} + C \end{aligned}$$

Nociones básicas de convergencia:

- Si $\|T\| < 1 \quad \forall \|\cdot\| \Rightarrow$ convergen todos.
- Si A es e.d.d \Rightarrow converge Jacobi y Gauss-Seidel.
- Si A es d.p $\wedge 0 < w < 2 \Rightarrow$ SOR converge.
- $\rho(T) < 1 \iff \mathbf{x}^{(k)} = T\mathbf{x}^{(k-1)} + C$ converge.
- $\zeta a_{ij} \leq 0 \quad \forall i \neq j \wedge a_{ii} > 0 \quad \forall i?$ por **Teorema 7.22**, tenemos que:
 - $0 \leq \rho(T_g) < \rho(T_j) < 1$. Si *converge*, G.S. converge más rápido.
 - $1 < \rho(T_j) < \rho(T_g)$. Si *diverge*, G.S. diverge más rápido.
 - $\rho(T_j) = \rho(T_g) = 1$. No convergen.

Cotas de error: Por Corolario 7.20, tenemos las siguientes **cotas de error**:

1. $\|\mathbf{x} - \mathbf{x}^{(k)}\| \leq \|T\|^k \|\mathbf{x}^{(0)} - \mathbf{x}\|;$
2. $\|\mathbf{x} - \mathbf{x}^{(k)}\| \leq \frac{\|T\|^k}{1 - \|T\|} \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|.$

2.1 Jacobi

Despejamos x_i del SEAL:

$$a_{11} x_1 + a_{12} x_2 + a_{13} x_3 = b_1 \quad \Rightarrow \quad x_1 = \frac{1}{a_{11}} [b_1 - (a_{12} x_2 + a_{13} x_3)]$$

$$a_{21} x_1 + a_{22} x_2 + a_{23} x_3 = b_2 \quad \Rightarrow \quad x_2 = \frac{1}{a_{22}} [b_2 - (a_{21} x_1 + a_{23} x_3)]$$

$$a_{31} x_1 + a_{32} x_2 + a_{33} x_3 = b_3 \quad \Rightarrow \quad x_3 = \frac{1}{a_{33}} [b_3 - (a_{31} x_1 + a_{32} x_2)]$$

$$x_i^{(k)} = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ i \neq j}}^n a_{ij} x_j^{(k-1)} \right)$$

2.2 Gauss-Seidel

$$x_i^{(k)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k-1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right)$$

2.3 SOR (Succesive Over-Relaxation)

$$x_i^{(k)} = (1 - w) x_i^{(k-1)} + \frac{w}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k-1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right)$$

2.4 Gradiente Conjugado

Elige las direcciones de búsqueda ($\mathbf{v}^{(k)}$) durante el proceso iterativo de modo que los $\mathbf{r}^{(k)}$ sean mutuamente ortogonales.

1. Partimos de un $\mathbf{x}^{(0)}$ y usamos la **dirección de máximo descenso** $\mathbf{r}^{(0)} = \mathbf{b} - A\mathbf{x}^{(0)}$ como $\mathbf{v}^{(1)}$.
2. Calculamos el paso de avance t en la dirección \mathbf{v} y la solución aproximada $\mathbf{x}^{(k)}$ (iniciamos con $k = 1$):

$$t = \frac{\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle}{\langle \mathbf{v}^{(k)}, A\mathbf{v}^{(k)} \rangle}, \quad \mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} + t_k \mathbf{v}^{(k)}.$$

3. Si $\mathbf{x}^{(k)}$ es la solución de $A\mathbf{x} = \mathbf{b}$ terminamos. Sino calculamos: $\mathbf{r}^{(k)} = \mathbf{b} - t_k A\mathbf{v}^{(k)}$, actualizamos el vector de búsqueda:

$$\mathbf{v}^{(k+1)} = \mathbf{r}^{(k)} + s_k \mathbf{v}^{(k)}, \quad s_k = \frac{\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}{\langle \mathbf{r}^{(k-1)}, \mathbf{r}^{(k-1)} \rangle},$$

y volvemos al paso 2.

2.4.1 Precondicionadores

Para solventar los casos en el que la matriz A a resolver esté mal condicionada, se propone un *precondicionamiento*. Es decir, encontrar una matriz P tal que: $\kappa(P^{-1}A) \approx 1$.

Jacobi. El precondicionamiento más simple es: $P = D_s$, con D_s diagonal de A . Es efectivo si la matriz es **diagonal dominante**.

Block-Jacobi. Una matriz con bloques de submatrices sobre la diagonal de A .

SOR: $P = (D_s + w L_s) D_s^{-1} (D_s + w U_s)$.

Cholesky incompleta. Si A es **simétrica, definida positiva**, puede descomponerse en: $A = C^T C = C^{*T} C^* + R$, con C^* una descomposición de *Cholesky* restringida a la estructura rala de A . Tomando $P = C^{*T} C^*$, se espera que el κ sea pequeño.

2.4.2 Criterios de Corte

Hay varias formas de decidir cuando detener el proceso iterativo:

- **Error absoluto:** $\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\| \leq \text{tolerancia}_1$. La tolerancia_1 depende del significado físico de la variable \mathbf{x} .
- **Error relativo** $\frac{\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|}{\|\mathbf{x}^{(k)}\|} \leq \text{tolerancia}_2$. Aquí se es independiente la tolerancia_2 de las unidades.
- **Error en la aproximación:** $\|\mathbf{r}^{(k)}\| \leq \text{tolerancia}_3 \cdot \|\mathbf{b}\|$. Es independiente de las unidades debido a que se refiere a la norma del vector de términos independientes.

@@TODO: Hay un apéndice en la diapositiva de iterativos. Revisar.

3 Solución de Ecuaciones No Lineales de una Variable

3.1 Método de la Bisección

El *método de la Bisección* procede buscando una raíz propuesta en la mitad del intervalo (a, b) , repitiendo iterativamente el proceso.

Es un método lento, de convergencia *lineal*, pero **siempre converge**. Es *robusto* (siempre encuentra solución), por lo que por esa razón es usado para iniciar otros métodos más eficientes.

Sea $f(x)$ **continúa** en $[a, b]$ y $f(a) \cdot f(b) < 0$. Entonces, por el **teorema del valor medio**, $\exists a < p < b / f(p) = 0$.

3.1.1 Algoritmo

Supongamos $a_1 = a$, $b_1 = b$, $i = 1$.

1. Calculamos el punto medio $p_i = a_i + \frac{b_i - a_i}{2} = \frac{a_i + b_i}{2}$.
2. Si $f(p_i) = 0 \Rightarrow p_i$, encontramos la raíz, y terminamos.
3. Si $f(p_i) \cdot f(a_i) < 0$:
 - Entonces, $b_{i+1} = p_i$, y $a_{i+1} = a_i$.
 - De lo contrario, $a_{i+1} = p_i$, y $b_{i+1} = b_i$.
4. Incrementamos i , y volvemos al paso 1.

3.1.2 Criterios de corte

Siendo una tolerancia $\mathcal{E} > 0$:

- **Error absoluto:** $|p_i - p_{i-1}| \leq \mathcal{E}$.
- **Error relativo:** $\frac{|p_i - p_{i-1}|}{|p_i|} \leq \mathcal{E}$.
Es independiente de las unidades y del significado físico de estas.
- **Error en la aproximación:** $|f(p)| \leq \mathcal{E}$.




Figure 1: Método de la Bisección, representación gráfica.

3.1.3 Cota de error

Del **Teorema 2.1**, supongamos que $f \in C[a, b] \wedge f(a) \cdot f(b) < 0$, entonces el método genera una sucesión $\{p_n\}_{n=1}^{\infty}$ que aproxima a un cero de p de f , tal que:

$$|p_n - p| \leq \frac{b - a}{2^n}, \text{ con } n \geq 1.$$

Otra cota de error fácilmente calculable (p72), es:

$$|p_n - p| < \frac{1}{2} |a_n - b_n|.$$

3.2 Iteración de Punto Fijo




Figure 2: Iteración de Punto Fijo, **convergencia** por $|g'(x)| < 1$ (izquierda), **divergencia** por $g'(x) < -1$ (medio), y por $|g'(x)| > 1$ (derecha).

3.2.1 Algoritmo

1. Se escoge una aproximación inicial p_0 .
2. Se genera la sucesión $\{p_n\}_{n=1}^{\infty}$, con $p_n = g(p_{n-1})$.
3. Si la sucesión converge en p y si g es continua, entonces:

$$p = \lim_{n \rightarrow \infty} p_n = \lim_{n \rightarrow \infty} g(p_{n-1}) = g(\lim_{n \rightarrow \infty} p_{n-1}) = g(p), \quad \text{y por:}$$

y obtenemos una solución con $p = g(p)$.

3.2.2 Cotas de error

Están dadas por el **Corolario 2.4**. Las cotas de error que supone utilizar p_n para aproximar p están dadas por:

$$|p_n - p| \leq k^n \max\{p_0 - a, b - p_0\},$$

$$|p_n - p| \leq \frac{k^n}{1 - k} |p_1 - p_0|, \quad \forall n \geq 1.$$

3.3 Método de Newton-Raphson

Sea $f \in C^2[a, b]$, el método construye una sucesión $\{p_n\}$ con la siguiente fórmula de recurrencia:

$$p_n = p_{n-1} - \frac{f(p_{n-1})}{f'(p_{n-1})}, \quad n \geq 1.$$

Convergencia: está dada por el **teorema 2.5**.

3.3.1 Cota de error (diapositiva):

$$e_{n+1} = |p_{n+1} - p| \approx e_n^2 \frac{f''(p)}{2f'(p)} = C e_n^2.$$

Nota: Ver además **Teorema 2.8**. De él concluimos que otra cota de error es (cumplidas las hipótesis):

$$|p_{n+1} - p| < \frac{M}{2} |p_n - p|^2.$$

3.3.2 M.N.R. con raíces múltiples (p84):

$$g(x) = x - \frac{f(x)f'(x)}{[f'(x)]^2 - f(x)f''(x)}.$$

3.4 Método de la Secante

Para solventar el problema del *método de Newton* de desconocer la derivada de la función, se utiliza este método.

La fórmula de recurrencia, basada en la definición de derivada, está dada por:

$$p_{n+1} = p_n - \frac{p_n - p_{n-1}}{f(p_n) - f(p_{n-1})} f(p_n).$$




Figure 3: Método de Newton-Raphson (*izquierda*), método de la Secante (*derecha*).

La **convergencia** es *superlineal*: $e_{n+1} = C e_n^{1.618\dots}$.

Requiere además dos estimaciones iniciales p_0 y p_1 .

3.5 Método de la Falsa Posición

Similar al *método de la secante*, pero en cada iteración toma -para trazar la secante- los dos últimos puntos que acotan la raíz buscada (como el *método bisección*).

Para determinar el punto que uso, evalúo:

$$f(p_n) \cdot f(p_{n-1}) < 0,$$

Si es **verdadero**, uso p_{n-2} , sino p_{n-1} , para seleccionar el intervalo con p_n .

CheatSheet

1. Operaciones en Matriz:

- $(E_i) \leftrightarrow E_j$.
- $(\lambda E_i) \rightarrow E_i$.
- $(E_i + \lambda E_j) \rightarrow E_i$.

2. Afirmaciones equivalentes (6.16):

- $A\mathbf{x} = \mathbf{0} \iff \mathbf{x} = \mathbf{0}$.
- $A\mathbf{x} = \mathbf{b}$ tiene solución única.
- $\exists A^{-1}$ (A es no *singular*).
- $\det A \neq 0$.
- Se puede *gaussear*.

3. Factorización LU:

\exists si *gaussemos* sin intercambio de renglones.

4. Resolver LU:

$$A\mathbf{x} = \mathbf{b} \rightarrow A = LU \rightarrow LU\mathbf{x} = \mathbf{b}$$

$$\rightarrow U\mathbf{x} = \mathbf{y} \rightarrow L\mathbf{y} = \mathbf{b}$$

5. Eliminación de Gauss:

$$a_{ij}^{(k+1)} = \begin{cases} a_{ij}^{(k)} & \text{si } i \leq k, \\ 0 & \text{si } i \geq k+1, j \leq k, \end{cases}$$

$$\text{En otro caso, } a_{ij}^{(k)} - \left(\frac{a_{ik}^{(k)}}{a_{kk}^{(k)}} a_{kj}^{(k)} \right).$$

6. Estrategias de pivoteo:

- **Simple:** buscar $a_{pk}^{(k)} \neq 0$.
- **Parcial:** buscar $a_{pk}^{(k)}$ con máximo **abs**.
- **Parcial Escalado:** buscar el pivote más grande en relación con su fila.

7. Estrictamente Diagonal Dominante:

$$|a_{ii}| > \sum_{j=1, i \neq j}^n |a_{ij}|, \quad \forall i \in [1, n].$$

8. Definida Positiva: Si es simétrica, y:

$$\mathbf{x}^T A \mathbf{x} > 0 \quad \forall \mathbf{x} \neq \mathbf{0}.$$

9. Sea A e.d.d:

- Es **no singular**.
- Tiene solución **única**.
- No se necesitan intercambio de renglones (tiene factorización LU).

10. Sea A definida positiva:

- A es **no singular**.
- $a_{ii} > 0 \quad \forall i$.
- $(a_{ij})^2 < a_{ii}a_{jj} \quad \forall i \neq j$.
- $\max_{1 \leq i, j \leq n} |a_{ij}| \leq \max_{1 \leq i \leq n} |a_{ii}|$.
- $\lambda_i > 0 \quad \forall i$.
- Podemos *gaussear* sin intercambio de renglones (tiene factorización LU) y los pivotes son positivos.
- Y, ¿es simétrica? $\iff \det(A_k) > 0 \quad \forall k$.
- Y, ¿ A es matriz \mathbb{R} ? \Rightarrow tiene factorización **única** $A = CC^T$, y $A = LDL^T$ con $L_{ii} = 1$ y $D_{ii} > 0$.

11. Norma vectorial:

- $\|\mathbf{x}\| > 0$.
- $\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0}$.
- $\|\alpha\mathbf{x}\| = |\alpha| \cdot \|\mathbf{x}\|$.
- $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$.
- **Euclídea:** $\|\mathbf{x}\|_2 = (\sum x_i^2)^{1/2}$.
- **Infinito:** $\|\mathbf{x}\|_\infty = \max\{|x_i|\}$.
- **L1:** $\|\mathbf{x}\|_1 = \sum |x_i|$.

12. Norma matricial:

- Ídem *norma vectorial* pero con matrices.
- $\|A\| = \max \|A\mathbf{x}\|$ con $\|\mathbf{x}\| = 1$.
- $\|A\mathbf{z}\| \leq \|A\| \cdot \|\mathbf{z}\|$.
- $\|AB\| \leq \|A\| \cdot \|B\|$.
- ¿ A es matriz **cuadrada**?
 $\Rightarrow \|A\|_\infty = \max \{\sum |a_{ij}|\}$.

13. Eigenvalue (λ): $(A - \lambda I) = 0$.

14. Radio espectral: $\rho(A) = \max |\lambda_i|$.

15. Número de Condición:

- $\kappa(A) = \|A\| \cdot \|A^{-1}\| = \frac{\lambda_{\max}}{\lambda_{\min}}$.
- Si $\kappa \approx 1 \Rightarrow$ **bien** condicionada.
- Si $\kappa \gg 1 \Rightarrow$ **mal** condicionada.

16. Afirmaciones equivalentes (7.17):

- A es una matriz **convergente**.
- $\lim_{n \rightarrow \infty} \|A^{(n)}\| = 0 \quad \forall \|\cdot\|$.
- $\lim_{n \rightarrow \infty} A^{(n)}\mathbf{x} = \mathbf{0} \quad \forall \mathbf{x}$.
- $\rho(A) < 1$.

4 Interpolación y aproximación de funciones